

Autoenkoderi za bežične komunikacije

End-to-end naučeni komunikacioni sistem

(7,4) autoenkoder

AWGN kanal

MATLAB R2023b

PyTorch

Nikola Bakić · EE58/2022 · FTN Novi Sad · jun 2026.



Problem klasičnog komunikacionog lanca

Klasičan digitalni sistem gradi se kao lanac **nezavisno projektovanih blokova**. Svaki blok je optimizovan zasebno, prema sopstvenom kriterijumu.

Cilj projekta: Posmatrati ceo lanac kao jednu neuronsku mrežu i trenirati predajnik i prijemnik zajedno, end-to-end, da minimizuju grešku rekonstrukcije poruke.



Svaki blok dizajniran nezavisno → lokalno optimalan, ali sistem nije zajednički optimizovan

O'Shea & Hoydis

2017

uveli pristup fizičkom sloju

(7,4)

$k=4, n=7$


4 info bita → 7 upotreba kanala

2 alata

MATLAB + PyTorch

nezavisna unakrsna validacija

Autoenkoderski pristup fizičkom sloju



Zašto AWGN kanal?

Backpropagation mora da prođe kroz kanal, pa kanal mora biti diferencijabilan. AWGN samo dodaje uzorke Gausovog šuma, što je diferencijabilna operacija. Tokom treninga je fiksni sloj, ne uči se.




Funkcija gubitka

Kategorijska unakrsna entropija nad $M = 16$ mogućih poruka. Mreža uči kodiranje i modulaciju samostalno, bez ijedne ručno projektovane komponente.

$$L = - (1/N) \sum \log p(s | y)$$

Struktura mreže i ključni parametri



Slika 1 · Struktura u MATLAB-u: ceo model, enkoder (Tx) i dekodler (Rx)

$k = 4$

informaciona bita

$n = 7$

upotrebe kanala

$M = 16$

moćućih poruka

$R \approx 0.571$

kodna brzina k/n

$E_b/N_0 = 3$ dB

training tačka

Energy

norm.

po uzorku, ne batch

wnorm ograničava energiju na jediničnu prosečnu snagu po uzorku

Postavka, baseline sistemi i trening

E_b/N_0 → varijansa šuma

$$\sigma^2 = 1 / (2R \cdot 10^{(Eb/N_0 / 10)})$$

Faktor 2: snaga se deli na realnu i imaginarnu komponentu kompleksnog simbola



Trening

- Adam optimizator uz smanjenje koraka na platou
- Training $E_b/N_0 = 3$ dB (fiksiran)
- Evaluacija BLER u opsegu 0 – 8 dB
- MATLAB R2023b → nezavisni PyTorch (Colab)

Četiri sistema u poređenju

1

Nekodovani QPSK

referentni baseline bez kodiranja

2

Hamming(7,4) + HDD

tvrdi odluka — gornja granica grešaka

3

Hamming(7,4) + MLD

optimalno (ML) dekodovanje koda

4

Autoenkoder (7,4)

naša end-to-end neuronska mreža

Slučajni procesi i vođenje simulacije

Emulirani slučajni procesi



Izvor poruka

uniformno slučajnih $M = 16$, one-hot kodovane



AWGN šum

nezavisni Gausovi uzorci, σ^2 po izrazu (1)



Rayleigh fading

$h \sim \text{CN}(0,1)$ po upotrebi kanala; samo u analizi aproksimacija



Inicijalizacija težina

slučajna početna tačka treninga

Vođenje simulacije



Trening

- Petlja po epohama; batch slučajnih poruka prolazi enkoder → kanal → dekoder
- Adam uz smanjenje koraka učenja na platou
- Kanal fiksiran na $E_b/N_0 = 3$ dB




Evaluacija (Monte Carlo)

- Sweep E_b/N_0 od 0 do 8 dB; po tački $\sim 10^5$ nezavisnih blokova
- BLER = broj pogrešnih blokova / ukupan broj
- Vrednosti ispod $\sim 10^{-4}$ ograničene brojem uzoraka (rep krive)

Run All u MATLAB Live Script-u vodi ceo tok: izgradnja mreže → trening → evaluacija sva četiri sistema → iscrtavanje.

Brza i stabilna konvergencija



Slika 2 · Kriva funkcije gubitka tokom treninga ($E_b/N_0 = 3$ dB)

≈ 0.095

vrednost gubitka u stabilnom režimu



Naglo opadanje


gubitak pada već u prvih nekoliko epoha



Stabilno

ravan plato bez oscilacija = stabilna konvergencija

Centralni nalaz: autoenkoder $\approx$ optimalan dekodler




Slika 3 · BLER iz MATLAB simulacije (AE Energy, Hamming HDD, Hamming MLD)

0.07 dB

gap autoenkodera u odnosu na optimalni MLD
na $BLER = 10^{-2}$

- **AE 4.22 dB · MLD 4.15 dB**
kriva autoenkodera se poklapa sa MLD celom dužinom
- **HDD zaostaje ≈ 1.3 dB**
tvrda odluka je osetno lošija od optimalnog dekodovanja
- **Bez ručnog dizajna**
mreža sama naučila kodiranje ekvivalentno Hamming-u

Sva četiri sistema i kodni dobitak



Slika 4 · BLER iz PyTorch reimplementacije (sva četiri sistema)


Tabela 1 · BLER na izabranim Eb/N0 tačkama

Eb/N0	QPSK	HDD	MLD	AE
2 dB	0.12	0.13	0.065	0.068
4 dB	0.046	0.037	0.012	0.013
6 dB	9.5e-3	5.2e-3	8e-4	1e-3
8 dB	7.5e-4	2.8e-4	2.5e-5	1.5e-5

Kolona AE (naglašeno) prati MLD vrlo blisko duž celog opsega.

1.73 dB kodni dobitak nad nekodovanim QPSK na $\text{BLER} = 10^{-2}$

PyTorch verno reprodukuje MATLAB




Slika 5 · Unakrsna validacija — PyTorch naspram MATLAB autoenkodera

< 0.3 dB

najveće odstupanje između
implementacija (srednji opseg)

- Krive se poklapaju duž celog opsega
- Razlike reda nekoliko desetih delova dB
- Uzrok: različita inicijalizacija težina i nezavisne realizacije šuma
- Zaključak: nezavisna implementacija potvrđuje rezultat

Mreža je pronašla sopstveno mapiranje



Slika 6 · Naučena konstelacija (PCA projekcija u 2D)

3.28

min. Euklidska
distanca · naučeni kod

3.46

min. Euklidska
distanca · Hamming + BPSK



Van standardne rešetke

Tačke nisu na QPSK/QAM mreži — mreža uči sopstveni raspored simbola.



Suštinski višedimenziono


PC1 i PC2 nose tek 16.1% i 15.5% varijanse; 2D je gruba projekcija 7D koda.



Manja distanca, isti BLER

Greška ne zavisi samo od min. distance, već od celog spektra i broja suseda.

Najuticajnija aproksimacija: idealan kanal



Slika 7 · Uticaj aproksimacije idealnog kanala — AWGN naspram Rayleigh

≈ 5.7 dB

degradacije na $BLER = 10^{-1}$ kada se model testira na Rayleigh fadingu

- **Bez retreniranja**
model treniran samo na AWGN testiran direktno na Rayleigh kanalu
- **Gubitak diverziteta**
blok fading bez CSI ruši red diverziteta — kriva opada znatno sporije
- **Ne dostiže 10^{-2}**
do 8 dB model praktično prestaje da funkcioniše

Pregled aproksimacija i procena uticaja

#	Aproksimacija	Uticaj	Izvor
1	AWGN kanal (bez fadinga)	$\approx 5.7 \text{ dB}$ na $\text{BLER } 10^{-1}$	Izmereno (Sl. 7)
2	Savršena sinhronizacija	0.5 – 2 dB u praksi	Literatura
3	Trening na fiksnom E_b/N_0	sub-optimalnost na ekstremima	Kvalitativno
4	Diskretni model (bez pulse shaping)	zanemaruje ISI	Kvalitativno
5	Float32 vs ADC/DAC rezolucija	0.1 – 0.5 dB	Literatura
6	Fiksna veličina bloka, bez ARQ	bez retransmisije	Kvalitativno
7	Idealan linearni pojačivač (PAPR)	1 – 3 dB back-off	Literatura

Crveno = sopstveni eksperiment. Kvantifikacija aproksimacije idealnog kanala je originalna kontribucija rada; ostalo su procene iz literature ili kvalitativne.

Šta smo pokazali



Ekvivalentno optimalnom

(7,4) autoenkoder samostalno uči kodiranje i modulaciju čije BLER performanse odgovaraju optimalnom (ML) dekodovanju Hamming koda — gap svega 0.07 dB, dobitak 1.73 dB nad nekodovanim QPSK.



Nezavisno potvrđeno

PyTorch reimplementacija reprodukuje MATLAB rezultat sa razlikom reda nekoliko desetih delova dB.



Granice modela

Pretpostavka idealnog AWGN kanala je najuticajnija: ≈ 5.7 dB degradacije na Rayleigh fadingu uz gubitak diverziteta bez retreniranja.



Dalji rad

- Trening na modelu kanala sa fadingom
- Dostavljanje CSI informacije mreži
- Robusnost na nelinearnost pojačivača
- Nesavršena sinhronizacija

Reference

- [1] **T. O'Shea, J. Hoydis** An Introduction to Deep Learning for the Physical Layer. IEEE Trans. Cogn. Commun. Netw., vol. 3, no. 4, pp. 563–575, 2017.
- [2] **The MathWorks, Inc.** Autoencoders for Wireless Communications. MATLAB Communications Toolbox documentation, R2023b.
- [3] **R. W. Hamming** Error detecting and error correcting codes. Bell System Technical Journal, vol. 29, no. 2, pp. 147–160, 1950.
- [4] **I. Goodfellow, Y. Bengio, A. Courville** Deep Learning. MIT Press, Cambridge, MA, 2016.
- [5] **N. Bakić** MiSKS Wireless Autoencoder. GitHub repository, 2026.

Hvala na pažnji.

Kod i demo



GitHub

nikolabakic/misks-wireless-autoencoder



MATLAB primer

mathworks.com — Autoencoders for Wireless



O'Shea & Hoydis

arXiv:1702.00832